

2026 年中国研究生数学建模竞赛 E 题：复杂场景下多模态情感预测

1. 先重新定义这道题：它不是三个独立小题，而是一个统一的“时序-缺失-解释”系统

这道题表面上分成三问：第一问做特征提取和时序对齐，第二问处理局部模态缺失，第三问做可解释性。真正高水平的建模不应该把三问拆成三个互不相干的模型，而应当把它们统一成一个带有**时间结构、可靠性结构、因果稳定性和证据结构**的多模态决策系统。

对任意样本，设文本、语音、视觉三种模态分别为

$$X^{(m)} = \{\mathbf{x}_t^{(m)}\}_{t=1}^{T_m}, \quad m \in \{T, A, V\},$$

其时间长度、采样频率和特征维度均不相同。进一步引入四类核心变量：

Z_t : 潜在情感状态, $R_t^{(m)}$: 模态可用性, $Q_t^{(m)}$: 模态可靠性, Y : 最终情感标签.

其中 $R_t^{(m)} \in \{0, 1\}$ 表示某个时间位置是否真实可观测, $Q_t^{(m)} \in [0, 1]$ 则表示即使“可观测”, 该位置的信号是否值得信任。二者必须区分：画面未缺失不代表画面清晰，语音不为零不代表语音没有噪声，文本存在也不代表该词对当前情感有判别力。

因此整道题的统一目标可以写成

$$\mathcal{F} : \{X^{(m)}, R^{(m)}\}_{m=T,A,V} \longrightarrow (\hat{y}, \hat{c}, \alpha_T, \alpha_A, \alpha_V, \mathcal{E}),$$

其中 $\hat{y} \in [-3, 3]$ 为情感强度, $\hat{c}$ 为 Negative/Neutral/Positive 三分类结果, α_m 为样本级模态作用程度, $\mathcal{E}$ 为可回放到原视频时间轴的关键证据集合。

本方案把统一框架命名为 **TRACE-MSA**: Temporal Reliability-Aware Causal Evidence Multimodal Sentiment Analysis。它不是为了“起一个新名字”，而是为了明确五条主线：**时间对齐 (Temporal)**、**可靠性估计 (Reliability)**、**自适应融合 (Adaptive)**、**因果稳定表征 (Causal)**、**证据解释 (Evidence)**。

2. 全题最关键的建模选择：问题 2 和问题 3 主线优先采用 **unaligned_50**，而不是 **aligned_50**

赛题同时提供 aligned_50.pkl 和 unaligned_50.pkl。若只追求快速跑通，aligned_50 更简单；但若追求高水平建模，建议将 **unaligned_50** 作为主线，**aligned_50** 作为基线与消融。

原因不是“unaligned 更复杂所以更高级”，而是它与题目的两个核心难点天然一致：

1. **局部缺失的本质是时间局部事件**。对齐后所有模态都压缩成 50 个位置，会把音频和视觉原本更细的局部缺失边界抹平；unaligned 中语音、视觉保留到最多 500 个位置，更适合研究“缺失发生在哪里、持续多久”。
2. **可解释性的本质是定位证据**。关键语音片段和关键表情往往持续很短，越早做粗粒度

平均，越难把证据精确回放到原视频。

3. **模态异步本身就是需要建模的对象。**直接使用 aligned 特征，相当于把最有价值的“跨模态对齐问题”提前替模型解决了；使用 unaligned 可以让模型显式学习“某句话、某个声学峰值、某个表情变化”之间的软对应关系。

因此主模型采用“各模态原生时间轴编码 + 潜在空间软对齐”，而不是“先粗暴插值到完全相同长度再融合”。这也是整套方案与普通竞赛解法拉开层次的第一个地方。

3. 问题 1：从原始视频到可核验多模态时间序列，核心不是提特征，而是建立可追溯的时间坐标系

3.1 原始数据处理原则：所有特征必须带着“时间身份证”进入模型

问题 1 最容易做成“分别用三个工具提特征，然后拼在一起”。这种方法能完成任务，但研究深度不够。真正需要建立的是一个样本级时间坐标系。设视频总时长为 D ，定义绝对时间轴 $\tau \in [0, D]$ 。任何文本词元、音频帧、视频帧在进入模型前，都必须保存：

(sample_id, modality, index, t_{start} , t_{end} , valid_flag).

这样做的意义是：第一问生成的不只是“特征矩阵”，而是第二问鲁棒性分析和第三问解释回放所需的证据索引系统。

3.2 文本、语音、视觉三模态的特征设计

文本模态。使用题目给定英文转写作为唯一语义文本，不额外引入外部情感语料。先通过强制对齐工具把给定 transcript 与视频音频对齐，得到词级时间区间 $[s_i^T, e_i^T]$ ；再用冻结的 BERT 类编码器获得 768 维上下文表示。这里不建议重新让 ASR 自由转写再替换题目文本，因为那会引入“文本内容发生改变”的额外误差源。

语音模态。将音频统一成单声道 16 kHz。以短时帧提取声学描述子，如基频、能量、谱形、声门与音质相关统计，再映射到固定维度表示。若希望与附件 2 接口尽量一致，可采用 74 维声学特征体系；更重要的是保存每一帧的真实时间位置，而不是只保留整段统计量。

视觉模态。对每一帧执行人脸检测与跟踪，提取面部动作、头姿、视线或深层表情表示。对于人脸未检测、严重遮挡等情况，不应简单把它当成“正常的零向量”，而要同步产生视觉有效性标记 $R_t^{(V)}$ 和质量分数 $Q_t^{(V)}$ 。这样第二问才能区分“真正缺失”和“数值恰好很小”。

3.3 两阶段时序对齐：确定性时间重叠 + 可学习软校正

第一阶段建立可复核的确定性时间重叠对齐。将总时长划分为 K 个时间锚点区间

$$I_k = [\tau_{k-1}, \tau_k), \quad k = 1, \dots, K,$$

其中 K 可设为 50 以兼容赛题标准接口。对模态 m 的第 i 个局部特征，其时间区间为 $J_i^{(m)}$ ，定义重叠权重

$$w_{ki}^{(m)} = \frac{|I_k \cap J_i^{(m)}|}{|J_i^{(m)}| + \varepsilon}.$$

则粗对齐特征为

$$\tilde{\mathbf{x}}_k^{(m)} = \frac{\sum_i w_{ki}^{(m)} \mathbf{x}_i^{(m)}}{\sum_i w_{ki}^{(m)} + \varepsilon}.$$

这一步的优点是每一个对齐结果都能回溯到具体原始时间段，适合论文中做“典型样本对齐验证”。

第二阶段在模型内部做带时间惩罚的局部软对齐。对第 k 个语义锚点与模态 m 的原生时间序列，定义

$$a_{kj}^{(m)} = \text{softmax}_j \left(\frac{\mathbf{q}_k^\top \mathbf{k}_j^{(m)}}{\sqrt{d}} - \lambda_t \frac{|\tau_k - \tau_j^{(m)}|}{D} \right),$$

并限制只在局部时间窗 $|\tau_k - \tau_j^{(m)}| \leq \Delta$ 内计算。这样既允许“语义事件与表情/语调存在轻微时间滞后”，又不会让模型产生跨很远时间的伪对齐。

这比纯 DTW 或简单线性插值更合理：前者只依赖距离度量，后者默认完全同步，而真实情感表达存在明显的跨模态反应延迟。

3.4 第一问真正应该提交什么样的中间结果

除了三模态特征文件，还应生成一个 **alignment_map**：对每条样本、每个统一位置记录文本词元、音频帧范围、视频帧范围、起止秒数、有效长度、缺失/填充标记。这个映射表会直接成为第三问解释结果“回放至原视频”的桥梁。

第一问的验证不只看“维度对不对”，还要验证：

- 覆盖完整性：100 条样本是否一一对应；
- 时间守恒：对齐前后有效时长是否一致；
- 单调性：时间索引是否严格不逆序；
- 对齐稳定性：轻微改变帧率或分段边界后，对齐结果是否大幅漂移；
- 典型样本可视化：一句话、对应语音峰值和表情变化是否落在近邻时间窗。

4. 问题 2：局部模态缺失不是“补零问题”，而是“缺失干预下保持预测机制不变”的鲁棒学习问题

4.1 首先区分三类零：填充零、真实缺失零、正常低幅值

赛题明确指出局部缺失表现为连续区间特征全为零。若直接把“零”送入模型，模型可能把填充区、真实缺失区和正常低幅值混为一谈。因此需要显式构造三类掩码：

$P_t^{(m)}$ ：有效长度掩码， $M_t^{(m)}$ ：局部缺失掩码， $O_t^{(m)} = P_t^{(m)} M_t^{(m)}$ ：真实可观测掩码。

对于有长度字段的音频和视觉，只在 $t \leq L_m$ 的区域内检测连续全零区间；超过有效长度的零一律视作 padding，不计入缺失率。这一细节非常重要，否则鲁棒性实验会被大量 padding 污染。

4.2 缺失模拟不能使用独立 Bernoulli dropout，要模拟“连续块缺失”

测试集的缺失是随机连续区间，因此训练阶段不能只做独立位置 dropout。对每个训练样本构造干预 $\mathcal{I}$ ：随机选择缺失模态集合、缺失起点和缺失长度，形成连续块掩码

$$M_t^{(m)}(\mathcal{I}) = \begin{cases} 0, & t \in [s_m, s_m + \ell_m), \\ 1, & \text{otherwise.} \end{cases}$$

缺失比例 $\rho_m = \ell_m / L_m$ 不固定在单一点，而应覆盖从轻度到重度的范围，并使用课程式训练：先训练短缺失，再逐渐提高长缺失和多模态同时缺失的比例。

关键原则是：**附件 3 只用于最终无标签推理，不利用其缺失分布反向调参**。这样可以避免隐性 test leakage。

4.3 全模态教师 + 缺失学生：把“完整信息下的预测机制”蒸馏给缺失模型

先训练一个只看完整三模态的 Teacher F_T ，得到完整信息下的隐表示 H_T 和输出分布 p_T 。再训练 Student F_S ，输入人为制造局部缺失后的数据。Student 不只拟合真实标签，还要逼近 Teacher 在同一样本完整输入上的行为：

$$\mathcal{L}_{\text{pred}} = \lambda_c \mathcal{L}_{\text{CE}}(c, \hat{c}) + \lambda_r \mathcal{L}_{\text{Huber}}(y, \hat{y}) + \lambda_\rho (1 - \text{Corr}(y, \hat{y})),$$

$$\mathcal{L}_{\text{KD}} = \text{KL}(p_T \| p_S) + \eta_1 \|H_T - H_S\|_2^2 + \eta_2 \|G(H_T) - G(H_S)\|_F^2.$$

其中 $G(H)$ 表示模态间或时间位置间的高阶相关矩阵。最后一项不是只让学生“结果像老师”，而是让缺失后的内部关系结构也尽量接近完整模态结构。

4.4 用“潜在变量重建”代替“原始特征硬补全”

直接把缺失的 768 维文本、74 维语音或 35 维视觉原样补出来并不必要，因为预测任务只关心与情感有关的部分。更合理的做法是先由各模态编码器得到低维潜在序列

$$H^{(m)} = E_m(X^{(m)}, O^{(m)}) \in \mathbb{R}^{L_m \times d},$$

再只重建与预测相关的潜在表示。

在每个局部时间邻域构建一个三模态超图，文本、音频、视觉节点属于同一“情感事件”超边。对可观测节点做高阶聚合，得到上下文 C_k ，然后对缺失模态预测高斯潜变量：

$$q(\hat{H}_k^{(m)} | C_k) = \mathcal{N}(\mu_k^{(m)}, \text{diag}((\sigma_k^{(m)})^2)).$$

训练时只在被人工遮掉的位置上计算重建负对数似然：

$$\mathcal{L}_{\text{rec}} = \sum_{(m,k) \in \Omega_{\text{mask}}} \left[\frac{\|H_{k,\text{full}}^{(m)} - \mu_k^{(m)}\|_2^2}{2(\sigma_k^{(m)})^2} + \log \sigma_k^{(m)} \right].$$

这样同时得到两个东西：缺失区域的潜在补全值 μ ，以及补全不确定性 σ 。后者将直接进入自适应融合。

4.5 因果稳定性：让模型学到“缺失方式变化时仍不变的情感因素”

将完整样本与其缺失干预版本看成一对反事实视图：

$$X_i \quad \text{与} \quad X_i^{(I)}.$$

二者的真实情感标签相同，变化的只是观测机制。定义完整和缺失条件下的因果稳定表示 Z_i 、 $Z_i^{(I)}$ ，加入

$$\mathcal{L}_{\text{inv}} = \|Z_i - Z_i^{(I)}\|_2^2 + \gamma \text{KL}\left(p(\hat{c} | X_i) \| p(\hat{c} | X_i^{(I)})\right).$$

这相当于告诉模型：缺失机制是环境变量，不应该改变真正与情感标签存在稳定关系的表示。它比普通数据增强更有理论解释，也更接近因果不变学习的思路。

4.6 可靠性驱动的动态模态专家：不是固定加权，而是“谁可靠谁多说话”

为每个模态建立专家输出 $u^{(m)}$ ，并由四类信号估计可靠性：

- 当前模态的可观测比例；
- 潜在重建不确定性 $\sigma^{(m)}$ ；

- 单模态预测熵;
- 与其他模态的跨模态一致性。

定义可靠性分数 q_m , 路由器给出

$$\alpha_m = \frac{\exp(s_m - \lambda_u u_m + \lambda_q \log(q_m + \varepsilon))}{\sum_j \exp(s_j - \lambda_u u_j + \lambda_q \log(q_j + \varepsilon))},$$

其中 s_m 是内容相关得分, u_m 是不确定性。融合表示为

$$Z = \sum_{m \in \{T, A, V\}} \alpha_m u^{(m)}.$$

路由器必须增加批级平衡约束, 避免训练后永远只依赖文本这一“强势模态”。但平衡约束只限制批量平均分布, 不能强迫每个样本三模态权重相等, 否则会破坏真实的样本差异。

4.7 分类与回归不能各做各的: 使用多任务一致性约束

赛题同时要求情感极性和连续强度。最合理的结构是共享编码器 + 两个任务头:

$$\hat{y} = 3 \tanh(\mathbf{w}_r^\top Z + b_r), \quad \hat{\mathbf{p}} = \text{softmax}(W_c Z + \mathbf{b}_c).$$

回归头天然限制在 $[-3, 3]$ 。分类头直接学习三分类标签, 同时增加弱一致性约束, 使“强烈正向回归值却给出 Negative 高概率”的情况受到惩罚。总损失可以写成

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda_1 \mathcal{L}_{\text{KD}} + \lambda_2 \mathcal{L}_{\text{rec}} + \lambda_3 \mathcal{L}_{\text{inv}} + \lambda_4 \mathcal{L}_{\text{cons}} + \lambda_5 \mathcal{L}_{\text{balance}}.$$

4.8 第二问不能只报一个 Accuracy 和一个 MAE, 要建立“鲁棒性响应面”

题目明确要求分析缺失模态类型、位置、时长的影响规律。因此应把鲁棒性分析变成一个独立数学模型, 而不是几张柱状图。

设缺失条件为

$$\omega = (m, \rho, p, n),$$

其中 m 为缺失模态类型, ρ 为缺失比例, $p \in \{\text{early}, \text{middle}, \text{late}\}$ 为缺失位置, n 为同时缺失的模态数。定义性能退化:

$$D_{F1}(\omega) = 1 - \frac{F1(\omega)}{F1(0)},$$

$$D_{MAE}(\omega) = \frac{MAE(\omega)}{MAE(0)} - 1, \quad D_r(\omega) = 1 - \frac{r(\omega)}{r(0)}.$$

再拟合广义加性响应面

$$D(\omega) = \beta_0 + \beta_m + s(\rho) + \beta_p + \beta_{m \times p} + s_m(\rho) + \epsilon.$$

这样可以回答的不只是“缺失越多越差”，而是：哪一种模态最脆弱、性能是否存在非线性崩溃阈值、头尾缺失与中间缺失是否等价、双模态缺失是否存在超加性损失。这才是题目所说“影响规律”的研究级表达。

5. 问题 3：可解释性不是画一张 attention 热力图，而是寻找“最小、充分、可验证”的决策证据

5.1 样本级模态作用程度：路由权重只是第一层解释

对完整三模态样本，时刻 k 的路由权重记为 $\alpha_{m,k}$ ，全局时间注意力为 β_k 。定义样本级模态作用度

$$I_m = \sum_k \beta_k \alpha_{m,k}, \quad \sum_m I_m = 1.$$

于是主要参考模态可以取 $\arg \max_m I_m$ 。但必须强调：注意力权重只能作为模型内部解释，不能直接视作因果解释。因此还需要第二层的反事实实验证。

5.2 局部证据分数：梯度筛选 + 反事实删除复核

先使用 Integrated Gradients 或输入梯度对所有时间位置快速获得候选重要度 $G_{m,k}$ 。再对前若干候选窗口执行真正的反事实删除：把该局部证据替换为基线或遮掉，重新计算预测，定义

$$\Delta_{m,k} = |\hat{y}(X) - \hat{y}(X^{(-m,k)})|.$$

若删除一个片段几乎不改变输出，那么即使 attention 很高，也不能把它当作核心证据。最终局部证据分数可以取

$$S_{m,k} = \text{Norm}(|G_{m,k}|) \cdot \text{Norm}(\Delta_{m,k}) \cdot Q_{m,k}.$$

其中 $Q_{m,k}$ 抑制低质量或高不确定区域，避免模型把“噪声峰值”解释成证据。

5.3 把“关键证据定位”写成一个约束优化问题

不是简单取 Top- K 点，而是寻找尽可能短、尽可能连续、同时真正能支持预测的证据集合 $\mathcal{E}$ 。定义两个标准：

充分性 (Sufficiency)：只保留证据后，模型预测仍接近原预测；

$$|f(X_{\mathcal{E}}) - f(X)| \leq \epsilon_s.$$

完整性/必要性 (Comprehensiveness): 删除证据后, 模型输出必须明显改变;

$$|f(X) - f(X_{\setminus \mathcal{E}})| \geq \delta_c.$$

于是关键证据选择可以写成

$$\min_{\mathcal{E}} (|\mathcal{E}| + \lambda_f \text{Frag}(\mathcal{E}))$$

$$\text{s.t. } |f(X_{\mathcal{E}}) - f(X)| \leq \varepsilon_s, \quad |f(X) - f(X_{\setminus \mathcal{E}})| \geq \delta_c.$$

其中 $\text{Frag}(\mathcal{E})$ 惩罚证据被切成很多零散碎片。这个设计很重要, 因为人在解释视频情感时通常需要的是“一段连续语音”“一句完整文本”“一段表情变化”, 而不是几十个孤立帧。

5.4 解释结果必须回到原始视频, 而不是停留在特征索引

对文本证据输出原始词/短语; 对语音输出 $[t_s, t_e]$ 秒; 对视觉输出 $[t_s, t_e]$ 秒及关键帧。时间映射优先使用问题 1 中建立的 `alignment_map`; 对于附件 4 的原始视频, 则重新执行同一套时间索引流程进行核验。

最终每条样本生成一张“解释卡”:

- 预测极性与连续强度;
- 三模态作用度 I_T, I_A, I_V ;
- 主要参考模态;
- 每个模态 Top 证据区间;
- 关键文本片段或视频时间段;
- Sufficiency、Comprehensiveness、解释稳定性等验证指标。

5.5 解释质量也要量化, 而不是只做案例展示


在验证集上至少评价三类指标:

1. **忠实性:** 删除高分证据后性能下降是否显著大于删除随机片段;
2. **充分性:** 只保留高分证据时预测能否基本保持;
3. **稳定性:** 输入加入极小扰动后, Top 证据区间是否大幅跳变。

若注意力权重与反事实删除结果矛盾, 应以反事实验证为主。这样就避免了很多“看起来很漂亮、实际上不忠实”的解释图。

6. 三个问题如何真正连成一个系统

整套 TRACE-MSA 的信息流可概括为：



其中问题 1 解决“信息如何进入系统”，问题 2 解决“信息残缺时系统如何稳定决策”，问题 3 解决“系统为什么这样决策”。三问共享同一个时间索引、同一个模态编码器和同一个可靠性思想，而不是三套互不兼容的方案。

7. 实验设计必须围绕“证明每个模块真的有用”，而不是只追求最终分数

高水平论文式实验至少应包含下列基线与消融：

实验类别	需要回答的问题
单模态基线	Text-only、Audio-only、Vision-only，判断数据本身是否存在强势模态。
简单融合基线	Early Concatenation、Late Fusion，证明复杂模型不是无意义堆叠。
对齐消融	aligned_50 与 unaligned_50 主线比较，验证细粒度时间结构是否值得保留。
缺失训练消融	无缺失增强、独立 dropout、连续块遮挡，验证缺失模拟方式的重要性。
蒸馏消融	去掉输出蒸馏、特征蒸馏、关系蒸馏，判断教师信息到底从哪一层起作用。
重建消融	不重建、确定性重建、带不确定性的潜变量重建，检验不确定性是否改善路由。
路由消融	固定平均、固定权重、动态权重、动态权重 + 可靠性，证明模型是否真的会“避开坏模态”。

实验类别	需要回答的问题
解释消融	attention-only、IG-only、IG+ 反事实删除，比较解释忠实性而不只比较可视化。

数据划分严格使用赛题给定 train/valid/test 逻辑：训练集拟合参数，验证集选模型、阈值和超参数，附件 3/4 不参与模型选择。所有标准化统计量、类别权重和校准阈值都只能由训练集或验证集产生。

8. 建议的评价体系：把“预测好、缺失稳、解释真”拆成三个互补维度

基础预测性能： Accuracy、F1、MAE、Pearson r ，严格对应题目要求。

鲁棒性： 除不同缺失条件下的 F1/MAE/ r 外，计算性能退化曲线和面积指标。例如对 F1 定义

$$AUR_{F1} = \int_0^{\rho_{\max}} \frac{F1(\rho)}{F1(0)} d\rho,$$

用来概括整个缺失强度区间，而不是只看一个缺失率。

解释质量： Sufficiency、Comprehensiveness、Top- K 稳定性、随机删除对照。解释模型如果无法通过反事实检验，就不能仅凭可视化图声称“可解释”。

9. 这套方案最值得写进论文“创新点”的五个地方

1. 从早期硬对齐改为“原生时间轴 + 可核验粗对齐 + 局部软校正”。保留模态异步信息，同时保持可追溯性。
2. 把局部缺失建模为观测机制干预，而不是普通噪声。通过完整/缺失反事实视图学习缺失不变表示。
3. 完整模态 **Teacher** + 缺失 **Student** + 高阶关系蒸馏。不只模仿最终标签，而是保持完整信息下的跨模态关系结构。
4. 重建值与重建不确定性同时进入动态路由。模型不是盲目补全后继续融合，而是知道“自己补得有多不确定”。
5. 把解释写成最小充分证据优化，并用反事实删除验证。从“可视化 attention”提升到“可量化、可复核、可回放”的证据解释。

10. 需要主动规避的高风险做法

- 不要把所有模态强行插值到完全相同长度后再做一个普通 Transformer，这会丢掉题目最重要的异步与局部缺失结构。
- 不要把 padding 的零和缺失的零混在一起；这是最容易导致实验结论失真的错误。

- 不要只用随机点 dropout 模拟缺失；测试条件是连续区间缺失。
- 不要直接把 attention 当作解释结论；必须增加干预式忠实性验证。
- 不要在附件 3、附件 4 上试阈值或挑模型；两者只能做最终推理。
- 不要在仅 4850 条样本上训练过重的大模型。更合理的是冻结预训练特征、使用中小型时序编码器，把复杂度用在缺失机制、可靠性和解释约束上。

11. 最终论文的主叙事

整篇论文可以围绕一句核心问题展开：

“当多模态信息异步、局部缺失且需要追溯决策依据时，如何让模型只依赖稳定、可靠、可验证的情感证据？”

第一问建立“证据在哪里”的统一时间坐标；第二问解决“证据缺失时还能不能稳定判断”；第三问回答“最终到底依赖了哪些证据”。如果后续代码、实验和论文都围绕这条主线组织，整体会比单纯堆叠 BERT、LSTM、Transformer、Attention 的常规解法更完整，也更接近高水平多模态学习论文的研究逻辑。

12. 方法论参考

本思路借鉴但不照搬近年来多模态情感学习中的几类研究思想：缺失模态的条件恢复与不确定性建模、相关结构蒸馏、动态模态专家、因果不变表征以及分布对齐。赛题给出的参考文献中已包含 Hypergraph Conditioned Diffusion、CMAD、EMOE、Proxy-Driven Robust Fusion、Causal Invariant Representation、CaReFlow 等方向。正式论文中应结合最终真正实现的模块引用对应文献，避免“没有实现却写成已采用”。