

2026 年中国研究生数学建模竞赛 E 题

复杂场景下多模态情感预测

学生版建模思路解析

通过网盘分享的文件：A163 2026 华为杯研赛赛题思路、代码及成品论文助攻资料合集！

链接：[点击打开百度网盘分享](#) 提取码：2026

来自百度网盘超级会员 v9 的分享

目录

写在前面	4
1 题目拆解与总体路线	4
1.1 先说清楚每一问最后要交什么	5
1.2 这道题最容易走偏的几个地方	5
1.3 版本选择	6
1.4 为什么先选对齐版	6
2 数据检查与符号约定	6
3 问题 1：特征提取与时序对齐	7
3.1 拿到数据后的第一小时做什么	7
3.2 先做一个最小基线	7
4 问题 1：把三种信号排到同一条时间线上	8
4.1 总体流程	8
4.2 文本模态	8
4.3 语音模态	8
4.4 视觉模态	9

目录	2
4.5 公共时间轴与定长化	9
4.6 超过 50 个词怎么办	9
4.7 问题 1 怎么证明自己做对了	10
4.8 建议保存结构	10
5 问题 2：局部模态缺失下的鲁棒预测	10
5.1 问题 1 常见失误	10
6 问题 2：有一段信息坏了，模型还能不能判断	11
6.1 连续缺失增强	11
6.2 模态编码与掩码感知	11
6.3 动态可靠性门控	12
6.4 联合分类与回归	12
6.5 推荐的三阶段训练顺序	13
6.6 实验设计	13
7 问题 3：可解释性预测	14
7.1 缺失规律怎么画图	14
7.2 附件 3 最终推理前再检查一次	15
8 问题 3：模型为什么这样判断	16
8.1 模态作用程度	16
8.2 关键证据定位	16
8.3 解释卡可以长什么样	17
8.4 解释忠实度检验	17
9 提交文件设计	18
9.1 问题 3 最容易出现的假解释	18
10 代码怎么组织，才不会越写越乱	19
11 提交结果怎么整理	19
12 训练、验证与风险控制	20
13 论文中最值得突出的创新点	20

目录	3
14 论文怎么写才不空	20
15 推荐实施顺序	21
16 结论	21
17 训练与验证时必须守住的边界	21
18 一份可以照着执行的顺序	22
19 学生常问的几个问题	22
20 最后检查清单	23

数字建模老哥

摘要

本文给出一条贯穿三个问题的统一建模路线：首先，以词级时间区间作为公共时间坐标，完成文本、语音和视觉特征的提取、聚合与定长化；其次，构建掩码感知的动态可靠性融合网络，在训练阶段主动模拟连续区间缺失，并联合使用分类、回归、重构和一致性损失，提高局部模态缺失条件下的稳定性；最后，通过模态反事实消融与局部滑窗遮挡量化模型决策依据，输出可复核的主要参考模态和关键证据时段。该方案优先选用题目提供的 `aligned_50.pkl`，使三问共享统一的 50 个时间位置和输入接口，并通过固定数据划分、严格掩码管理、消融实验和解释忠实度检验保证结论可复现。

写在前面

这份材料不是正式论文，也不是一份必须照抄的“标准答案”。它更像一次赛前讨论：题目到底要我们做什么，先跑哪一步，模型为什么这么搭，实验结果出来以后又该怎么解释。公式会有，但公式后面尽量都用普通话再说一遍。

先提醒一句：这道题很容易一上来就堆模型。Transformer、图网络、扩散模型都能写，但数据读取、掩码和评价指标只要错一个，后面的结果就没有意义。比较稳的做法是先把最简单的基线跑通，再逐层加东西。每加一个模块，都要能回答两个问题：它解决了什么毛病？拿掉以后指标会不会变差？

全文按“先看懂题目，再做数据，再做模型，最后考虑论文怎么落笔”的顺序写。这里先把建模思路讲清楚，不展开口头汇报稿。

1 题目拆解与总体路线

题目不是三个彼此独立的任务，而是一条逐层递进的链条：问题 1 解决“输入如何形成”，问题 2 解决“信息不完整时如何预测”，问题 3 解决“为什么得到该预测”。建议将整套方法命名为“掩码感知、证据可追溯的多模态情感预测框架”（Mask-aware Evidence-traceable Multimodal Sentiment Framework, MEMS）。把题目压缩成一句话，就是：先把视频里的文字、声音和画面排到同一条时间线上；再研究其中一部分坏掉时还能不能判断情绪；最后告诉读者，模型到底凭什么作出这个判断。

三个问题前后有关系。问题 1 决定输入是否靠谱。问题 2 在问题 1 的输入上人为制造缺失，再训练模型扛住这些缺失。问题 3 继续使用同一套时间位置，把“第 17 个位置很重要”翻译回原视频里的具体句子、声音区间和画面。三问如果各写各的，论文会很散；如果共用一套时间轴、掩码和模型主干，叙述会顺很多。

为了后面写论文和做汇报方便，可以给方法取一个短名字，例如 MEMS。名字本身不重要，重要的是后面所有图表都用同一套说法，不要一会儿叫动态融合，一会儿又叫自适应集成。

表 1: 三问的核心矛盾、方法与输出

问题	核心矛盾	建模抓手	必须输出
问题 1	三模态采样频率和时间尺度不同	词级强制对齐、区间池化、掩码与映射表	50 步三模态特征、有效长度、时间戳、处理日志
问题 2	连续局部区间缺失导致固定融合失效	缺失增强、掩码编码、动态门控、重构与一致性约束	极性、强度、缺失因素影响规律、附件 3 预测
问题 3	模型结论缺少可复核证据	模态反事实贡献、局部滑窗遮挡、忠实度评价	主要模态、作用程度、关键文本/音频/帧段、附件 4 解释

1.1 先说清楚每一问最后要交什么

问题 1 不是“介绍几个特征提取工具”就结束。真正要交的是 100 条视频对应的三模态特征、有效长度、填充位置、时间戳和处理记录。评委应该能从一个特征位置顺着记录找到原视频中的那一小段。

问题 2 要同时给出三分类结果和连续强度。除了总指标，还得说明哪种模态缺失最伤、缺多长开始明显掉点、缺在开头和缺在中间有没有区别。附件 3 没有标签，只负责最终预测，不能拿它调参数。

问题 3 不只要画一张注意力热力图。题目要求的解释必须能复核：主要参考了文字、语音还是画面？占多大作用？关键证据在第几秒？最好还能做一个反向检查，把这段证据遮掉以后，模型的输出确实发生明显变化。

1.2 这道题最容易走偏的几个地方

第一，别把补零直接当成缺失。序列长度不到 50 时也会补零，这是正常填充；附件 3 中的连续零段才是题目关心的局部缺失。两者如果混在一起，缺失率统计会乱。

第二，别先碰附件 3 和附件 4。它们没有标签，看到结果也不知道好坏。训练集学参数，验证集选结构和阈值，专项测试集只在最后推理一次。这个顺序要守住。

第三，别只报 Accuracy。中性样本往往少，模型全部猜正负也可能得到看上去不错的准确率。分类至少同时看 Macro-F1；回归至少同时看 MAE 和 Pearson 相关系数。

第四，别把“可解释”写成模型自己说故事。我们后面用反事实遮挡：把某个模态或某个时间窗口拿掉，看预测变化多少。变化越大，说明这部分证据越关键。这个逻辑不花哨，但容易复核。

1.3 版本选择

主方案选择 `aligned_50.pkl`。原因如下：

1. 三模态均为 50 个相互对应的位置，便于建立统一缺失掩码；
2. 解释结果可直接回映到同一时间位置，证据定位更清晰；
3. 模型复杂度和计算量低于非对齐版本，适合竞赛有限时间内完成多组消融；
4. 附件 3、附件 4 均提供对应版本，可保证训练、验证和专项测试接口一致。

可将 `unaligned_50.pkl` 作为补充对照，而不建议两套版本在同一模型中混用。

1.4 为什么先选对齐版

对学生来说，对齐版更适合作为第一条完整路线。文本、语音、视觉都是 50 个位置，写数据加载器时不必同时维护三套长度；做缺失实验时，某个区间也能直接落在相同的位置上；最后定位证据，三种模态还能放在同一张横轴图里比较。

非对齐版并不是没价值。它保留了更多语音和视觉细节，理论上可能带来更好的结果，但模型需要另外处理 50 对 500 的时间尺度差异。比赛时间紧时，先把对齐版做完整，比两套数据都做一半更稳。如果对齐版已经跑通且还有时间，再把非对齐版作为补充实验。

2 数据检查与符号约定

对每个样本记文本、语音、视觉特征为

$$X^{(t)} \in \mathbb{R}^{50 \times 768}, \quad X^{(a)} \in \mathbb{R}^{50 \times 74}, \quad X^{(v)} \in \mathbb{R}^{50 \times 35}.$$

对应的有效位置掩码为 $M^{(m)} \in \{0, 1\}^{50}$ ，其中 $m \in \{t, a, v\}$ 。标签包括三分类极性 $c \in \{0, 1, 2\}$ 和连续强度 $y \in [-3, 3]$ 。

正式训练前应完成以下审计：

- 检查各字段样本数和 id 顺序是否完全一致；
- 区分“填充零”和“真实零”，所有缺失判断必须与有效长度、显式掩码共同使用；
- 统计三类标签占比、强度分布、片段长度和各模态特征尺度；
- 仅使用训练集估计均值、标准差，再应用到验证集与测试集，防止数据泄漏；
- 对零方差维度保持为零，不进行除零操作；
- 固定题目给定的训练/验证/测试划分，不自行重划导致结果不可比。

3 问题 1：特征提取与时序对齐

3.1 拿到数据后的第一小时做什么

不要急着训练。先写一个只负责“看数据”的脚本，逐个打印训练、验证、测试三部分的字段名、数组形状、数据类型、最大值、最小值、均值、零值比例和标签分布。随机抽三条样本，把 `id`、`raw_text`、类别标签和强度标签一起打印出来，人工确认它们没有错位。

然后做一张数据体检表。下面这些数字以后都能直接写进论文：

表 2: 建议先统计的数据概况	
检查项	要回答的问题
样本数量	训练、验证、测试各有多少条，三种模态的第一维是否一致
标签分布	负向、中性、正向各占多少，连续强度是否集中在某个区间
有效长度	50 个位置里平均有多少个有效位置，短样本比例多不多
零值比例	零值来自尾部填充、局部缺失，还是提取失败
特征尺度	文本、语音、视觉的数值范围是否差很多，是否需要标准化
异常样本	是否出现全零模态、NaN、无穷值、空文本或重复 ID

这一步看起来不“高级”，却能省很多时间。比如训练损失一直不降，常见原因并不是网络太浅，而是标签读错列、有效位置被当成填充，或者标准化时把验证集也算了进去。

3.2 先做一个最小基线

建议先把三个模态分别做掩码平均池化，再拼接成一个向量，接两层全连接网络，同时输出分类和回归。这个模型不一定强，但它能检查整条链路：数据能否正常读入，损失能否下降，评价函数是否正确，保存与加载模型是否正常。

如果这个简单模型都跑不通，不要上 Transformer。先从十条样本过拟合开始。十条样本都记不住，通常说明代码还有问题；能记住以后再恢复完整训练集。这个调试办法很朴素，但比赛里很好用。

4 问题 1: 把三种信号排到同一条时间线上

4.1 总体流程

原始视频处理流程为：视频完整性检查 → 音视频分离 → 文本强制对齐 → 三模态逐帧/逐词特征提取 → 公共时间区间聚合 → 定长化 → 质量审计与保存。问题 1 先别想得太玄。每段视频里有人说话，声音在变化，脸也在变化。我们要做的，是把一句话拆成若干时间区间，再问：这个区间说了什么，声音听起来怎么样，画面里的人是什么表情。三组答案排成相同长度的序列，问题 1 就有了主干。

完整流程可以写成：视频检查 → 音视频分离 → 给文本补时间戳 → 分别提取三模态特征 → 按共同时间区间聚合 → 统一到 50 个位置 → 保存映射和日志。

这里最重要的不是选了哪个预训练模型，而是记录能不能对得上。第 12 个位置如果被模型判为关键证据，我们要知道它对应原视频的哪几秒、哪几个单词和哪些画面帧。

4.2 文本模态

使用题目给出的英文转写文本，先进行轻量规范化，但保留原始文本字段。将文本输入 BERT-base 类编码器，获得每个词元的 768 维上下文表示。若一个单词被拆成多个子词，则对子词表示取均值：

$$\mathbf{x}_i^{(t)} = \frac{1}{|S_i|} \sum_{j \in S_i} \mathbf{h}_j,$$

其中 S_i 为第 i 个单词对应的子词集合。为避免引入额外训练数据，预训练模型只用于通用特征提取，不利用其他情感数据进行微调。

文本时间戳通过“给定转写文本 + 原始音频”的强制对齐获得。可采用 WhisperX/Montreal Forced Aligner；当强制对齐失败时，按标点和单词数将片段划分为近似区间，并记录 `alignment_quality=low`，不得静默删除样本。

一个实际例子：假设文本是 “I really enjoyed this movie”，强制对齐后得到五个单词的起止时间。BERT 负责把每个单词变成 768 维向量。若 “enjoyed” 被分成两个子词，就把两个子词向量取平均，重新得到一个单词位置。这样后面展示证据时，学生和评委看到的是正常单词，而不是难以理解的子词编号。

4.3 语音模态

从视频提取单声道、16 kHz 音频。使用 openSMILE/COVAREP 类工具提取音高、能量、谱特征、共振峰、声音质量等低层描述符。为与题目接口一致，最终保留或投影为 74 维。对第 i 个词级时间区间 $I_i = [s_i, e_i]$ 内的音频帧集合 A_i 做统计池化：

$$\mathbf{x}_i^{(a)} = \frac{\sum_{k: \tau_k \in I_i} q_k \mathbf{a}_k}{\sum_{k: \tau_k \in I_i} q_k + \varepsilon},$$

其中 q_k 为音频帧质量权重, 可由信噪比或有效语音概率给出。当区间内没有有效音频帧时, 置零并令该位置掩码为 0。

大白话解释一下: 一个单词可能持续 0.4 秒, 这 0.4 秒里会有很多个短音频帧。模型最后只需要一个 74 维向量, 所以把这些帧按质量加权平均。背景噪声很大的帧权重小一点, 清楚的语音帧权重大一点。没有可靠声音时不要硬填均值, 直接置零并告诉模型“这里缺了”。

4.4 视觉模态

以固定帧率抽帧, 采用 OpenFace/MediaPipe 类工具提取面部动作单元、头部姿态、视线和表情几何特征, 最终组织为 35 维。对时间区间 I_i 内视觉帧作质量加权池化:

$$\mathbf{x}_i^{(v)} = \frac{\sum_{k:\tau_k \in I_i} r_k \mathbf{v}_k}{\sum_{k:\tau_k \in I_i} r_k + \varepsilon},$$

其中 r_k 由人脸检测置信度、遮挡程度和关键点完整率确定。未检测到可靠人脸的区间置零, 同时保留缺失掩码。

视觉模态也一样。一个词对应的时间段里往往有多帧画面。先逐帧提取面部动作单元、头部姿态和视线, 再做区间聚合。人物转头、被挡住或者根本没有脸时, 检测置信度会降低。这个信息应该进入掩码, 而不是假装每一帧都同样可信。

4.5 公共时间轴与定长化

优先采用词级区间作为公共时间轴。若有效单词数 $L \leq 50$, 保留前 L 个位置并在尾部补零; 若 $L > 50$, 不宜简单截断, 而应将原时间轴等分为 50 个时间桶, 对落入同一桶的词、音频帧和视觉帧分别加权聚合。这样可保证片段尾部信息不被系统性丢弃。

对每个位置同时保存

$$(i, s_i, e_i, M_i^{(t)}, M_i^{(a)}, M_i^{(v)}),$$

从而能够把问题 3 中的位置索引重新映射为原视频时段、文本片段和关键帧编号。

4.6 超过 50 个词怎么办

最省事的做法是截掉第 51 个词以后所有内容, 但这会带来一个明显问题: 长视频的结尾永远看不到。如果情绪转折恰好发生在最后几秒, 模型会直接错过。

更稳妥的办法是把整段时间均匀分成 50 个桶。落入同一个桶的多个文本词向量、音频帧和视频帧分别池化。这个处理会损失一点细节, 却保住了整段视频的开头、中间和结尾。论文里要说明哪些样本发生了压缩, 压缩前后的长度分别是多少。

4.7 问题 1 怎么证明自己做对了

至少准备三类检查。第一类是数量检查:100 条样本是否都成功输出,文件名和 `video_id$_$clip_i` 是否一一对应。第二类是形状检查:三模态是否分别为 50×768 、 50×74 和 50×35 。第三类是人工检查:挑一条情绪比较明显的视频,画出时间轴,在同一位置放上单词、音频能量和关键帧。

典型样本不必挑预测最准的。最好选一条有情绪转折、三种模态都看得见的样本,这样对齐效果更容易说明。比如前半句语气平缓,后半句出现明显否定词,同时音调升高、表情收紧。把这些现象放在同一张图上,问题 1 的说服力就出来了。

4.8 建议保存结构

每条样本至少包含:

```
id, video_id, clip_id, raw_text, duration,
text[50,768], audio[50,74], vision[50,35],
text_mask[50], audio_mask[50], vision_mask[50],
start_time[50], end_time[50], valid_length,
alignment_quality, extraction_log
```

全量 100 条样本汇总表建议由程序自动生成,字段为样本编号、视频时长、有效位置数、三模态维度、有效比例、对齐方式、异常说明和输出文件校验值。典型样本图应在同一横轴上展示单词、音频波形/能量、视觉关键帧和三模态掩码。

5 问题 2: 局部模态缺失下的鲁棒预测

5.1 问题 1 常见失误

不要为了“覆盖完整”而悄悄复制错误特征。有的短视频可能没有稳定人脸,保留样本、视觉置零并记录原因,比随便拿前一帧顶上更合理。也不要只保存最终矩阵。没有起止时间、有效长度和处理日志,问题 3 就很难把证据映射回原视频。

工具版本也要记下来。比如 Python、PyTorch、Transformers、openSMILE、OpenFace 和 FFmpeg 的版本,抽帧率、音频采样率、BERT 模型名称、最大长度和池化规则。复现说明不是最后一天凭记忆补的,最好让程序启动时自动写入配置文件。

6 问题 2: 有一段信息坏了, 模型还能不能判断

6.1 连续缺失增强

先分清题目说的“缺失”是什么。它不是整段视频没有声音, 也不是整个视觉模态都消失, 而是某个模态在一段连续时间里不可用。比如第 15 到第 25 个位置的音频全为零, 前后位置仍然正常。这个设定很像现实中一阵噪声、几秒遮挡或者局部转写失败。

附件 3 中的缺失为连续区间, 因此训练时不能只做独立随机置零。对模态 m 随机采样缺失起点 s 和长度 ℓ , 构造

$$\widetilde{M}_i^{(m)} = M_i^{(m)} \cdot \mathbb{I}(i \notin [s, s + \ell - 1]).$$

训练阶段按一定概率生成单模态缺失、双模态同时缺失和三模态不同区间缺失。缺失率建议覆盖 10%, 20%, ..., 70%, 并对开头、中部、结尾三类位置分层采样, 使训练分布能够覆盖题目要求的影响因素。

每个批次同时保留完整视图 X 和缺失视图 $\widetilde{X}$ 。模型只能接收缺失后的特征和掩码, 完整视图仅用于教师约束, 避免推理信息泄漏。

训练时可以把一次缺失理解成一道随机出的“破坏题”。先随机决定破坏文本、语音还是视觉, 再决定从哪里开始、连续破坏多长。不能只遮中间, 也要覆盖开头和结尾; 不能只做 10% 的小缺失, 也要让模型见过 50% 甚至 70% 的困难情况。

建议把缺失生成器单独写成模块, 并把随机种子、模态、起点、长度记录到日志。这样发现某次训练异常时, 可以复现当时的掩码, 而不是只知道“随机增强好像出了问题”。

6.2 模态编码与掩码感知

先将不同维度映射到共同隐空间:

$$H^{(m)} = \text{Transformer}_m (X^{(m)} W_m + E_{\text{pos}} + E_m; M^{(m)}),$$

其中 E_{pos} 为位置编码, E_m 为模态类型编码。Transformer 的注意力计算显式屏蔽无效位置。然后利用掩码池化得到模态级表示:

$$z_m = \frac{\sum_i M_i^{(m)} H_i^{(m)}}{\sum_i M_i^{(m)} + \varepsilon}.$$

这一步可以这么理解: 三个模态先各学各的, 不急着混在一起。文本编码器负责看词语之间的关系, 语音编码器负责看语调随时间怎么变, 视觉编码器负责看表情和姿态。最后只对有效位置做平均, 缺失位置不参与计算。

如果比赛时间有限, 三个编码器不必都做得很深。两层 Transformer 或双向 GRU 已经可以作为合理起点。网络越大, 调参越慢, 也更容易在 4850 条样本上过拟合。先把掩

码处理正确, 比盲目加层数重要。

6.3 动态可靠性门控

定义模态缺失率

$$\rho_m = 1 - \frac{1}{50} \sum_{i=1}^{50} M_i^{(m)}.$$

由模态表示、缺失率和局部连续缺失统计共同估计可靠性得分:

$$g_m = \mathbf{w}_g^\top [\mathbf{z}_m; \rho_m; L_m^{\max}/50] + b_g, \quad \alpha_m = \frac{\exp(g_m - \lambda \rho_m)}{\sum_n \exp(g_n - \lambda \rho_n)}.$$

其中 $L_m^{\max}$ 是最长连续缺失区间。融合表示为

$$\mathbf{z} = \sum_{m \in \{t, a, v\}} \alpha_m \mathbf{z}_m + \text{CrossAttention}(H^{(t)}, H^{(a)}, H^{(v)}).$$

该结构使模型在某个模态局部严重缺失时自动降低其权重, 而非继续使用固定比例融合。

门控的直觉很简单: 哪路信息坏得多, 就少信一点; 哪路信息虽然完整但内容本身含糊, 也不必给高权重。 ρ_m 告诉模型“缺了多少”, 最长连续缺失长度告诉模型“坏得是否集中”, $\mathbf{z}_m$ 则反映剩余内容是否有用。

这里要保留一个直接拼接基线。只有当动态门控在完整数据上不明显掉点、在缺失数据上明显更稳时, 才能说它起作用。若完整输入反而变差很多, 说明门控可能过度惩罚某个模态, 或者损失权重没有调好。

6.4 联合分类与回归

由两个任务头分别输出

$$\mathbf{p} = \text{softmax}(W_c \mathbf{z} + b_c), \quad \hat{y} = 3 \tanh(W_r \mathbf{z} + b_r).$$

三分类由 $\arg \max_k p_k$ 给出, 强度预测天然限制在 $[-3, 3]$ 。不建议仅凭 $\hat{y} = 0$ 判断中性, 因为连续回归几乎不会恰好等于零; 应使用独立三分类头, 并用一致性约束协调两个任务。

总损失可设为

$$\mathcal{L} = \lambda_c \mathcal{L}_{\text{CE}} + \lambda_r \mathcal{L}_{\text{Huber}} + \lambda_d \mathcal{L}_{\text{distill}} + \lambda_{\text{rec}} \mathcal{L}_{\text{rec}} + \lambda_{\text{con}} \mathcal{L}_{\text{con}}.$$

其中:

$$\begin{aligned}\mathcal{L}_{\text{distill}} &= \text{KL}(\mathbf{p}_{\text{full}} \parallel \mathbf{p}_{\text{miss}}) + |\hat{y}_{\text{full}} - \hat{y}_{\text{miss}}|, \\ \mathcal{L}_{\text{rec}} &= \sum_{m,i} (1 - \widetilde{M}_i^{(m)}) \|\hat{H}_i^{(m)} - H_i^{(m)}\|_2^2, \\ \mathcal{L}_{\text{con}} &= |\hat{y} - (-\mu p_- + \mu p_+)|.\end{aligned}$$

这里的完整视图预测作为教师, 约束缺失视图输出稳定; 重构损失只在人工遮挡但原本可观测的位置计算。

五个损失不建议第一天全部打开。先用分类损失和回归损失把主任务跑通, 再加完整视图与缺失视图的一致性约束, 最后尝试重构。否则指标变坏时, 很难知道是哪一项造成的。

分类和回归为什么一起做? 三分类告诉我们方向, 连续值告诉我们程度。一个样本预测为正向, 同时回归值却是 -2.1 , 显然互相打架。一致性损失就是减少这种矛盾, 但它只能当辅助约束, 不能替代真实标签。

6.5 推荐的三阶段训练顺序

第一阶段只用完整数据, 训练三模态编码器、融合层和两个任务头。目标是得到一个正常的完整输入模型。第二阶段打开连续缺失增强和动态门控, 用较小学习率继续训练。第三阶段再加入一致性或重构损失, 并根据验证集决定是否保留。

这种分阶段做法比一开始把所有模块一起训练更好排错。每个阶段都保存最佳权重和验证指标。如果第二阶段的完整数据性能明显下降, 可以回退到第一阶段, 而不是整套重跑。

类别不平衡时, 可以按训练集类别频率设置交叉熵权重。回归损失建议用 Huber 损失, 它在误差小时接近平方损失, 在少数大误差上又不会像均方误差那样被极端样本牵着走。

6.6 实验设计

至少设置以下基线和消融:

1. 单模态文本、语音、视觉模型;
2. 直接拼接和固定权重融合;
3. 完整 MEMS;
4. 去除连续缺失增强、动态门控、重构损失、一致性蒸馏的四组消融;
5. 完整输入与不同模态、不同缺失率、不同缺失位置下的性能对比。

实验表不要临时想到一组跑一组。先列一个矩阵, 统一随机种子、训练轮数和早停规则:

表 3: 问题 2 建议实验矩阵

实验组	输入情况	模型改动	主要目的
完整基线	三模态完整	直接拼接	检查基本性能
缺失基线	连续区间缺失	直接拼接	测量自然退化
门控模型	连续区间缺失	加动态权重	判断门控是否有效
一致性模型	连续区间缺失	加完整-缺失约束	判断输出是否更稳定
重构模型	连续区间缺失	加隐空间重构	判断补偿信息是否有用
完整模型	连续区间缺失	全部模块	给出最终结果

分类报告 Accuracy、Macro-F1，回归报告 MAE、Pearson r 。定义性能退化量

$$\Delta Q(m, r, p) = Q_{\text{complete}} - Q(m, r, p),$$

其中 m 为缺失模态组合， r 为缺失率， p 为缺失位置。可进一步建立响应面或方差分析模型

$$\Delta Q = \beta_0 + \beta_m + f(r) + \beta_p + \text{eta}_{mr} + \beta_{mp} + \epsilon,$$

量化“缺失什么、缺失多少、缺失在哪里”三个因素及交互作用。预期文本缺失影响最大，但该结论必须由验证实验支持，而不能预先写死。

7 问题 3: 可解释性预测

7.1 缺失规律怎么画图

最直观的图是四条退化曲线。横轴为缺失率，纵轴分别画 Macro-F1、Accuracy、MAE 和 Pearson r 。文本、语音、视觉三种单模态缺失用不同颜色。还可以增加“文本 + 语音”等双模态缺失，但图例不要多到看不清。

缺失位置可以分成开头、中部、结尾三组，做箱线图或点图。若中部缺失明显更伤，可能是情绪表达的主体内容集中在中间；若结尾缺失更伤，可能存在结尾总结或情绪反转。这里不要只报数值，要结合典型文本和视频解释。

错误分析至少挑三类样本：预测稳定的、缺失后翻转的、完整输入本来就错的。第三类很重要，因为它说明有些错误并不是缺失造成的，而是原始内容含糊、三模态互相冲突或标签本身靠近零。

7.2 附件 3 最终推理前再检查一次

附件 3 没有标签, 所以输出前先检查模型处于评估模式, 标准化参数来自训练集, 输入版本与训练时一致, 掩码识别没有把正常零值误判为缺失。预测强度应裁剪到 $[-3, 3]$, 分类标签、概率和回归值要放在同一行, 并按题目给定 ID 顺序导出。

数字建模老哥

8 问题 3: 模型为什么这样判断

问题 3 的数据是完整的，难点不在补缺失，而在把判断依据说清楚。题目要的解释有两层：先回答三种模态谁更重要，再回答重要模态中的哪一段最关键。前一层是模态级解释，后一层是时间位置级解释。

这里有一个基本原则：解释必须能被重新计算。不能只写“模型主要参考了语义和语调”，因为这句话无法验证。我们要给出数值、时间段和原始证据，并做遮挡实验确认这些证据确实影响预测。

8.1 模态作用程度

仅报告注意力权重不足以证明解释可靠。建议采用“门控权重 + 反事实性能变化”的组合指标。对模态 m 整体遮挡，得到反事实预测 $\hat{y}_{-m}$ 和 $\mathbf{p}_{-m}$ ，定义

$$d_m = |\hat{y} - \hat{y}_{-m}| + \eta \text{JSD}(\mathbf{p}, \mathbf{p}_{-m}),$$

其中 JSD 为 Jensen-Shannon 散度。最终模态作用程度为

$$I_m = \frac{\gamma \alpha_m + (1 - \gamma) d_m / \sum_n d_n}{\sum_k [\gamma \alpha_k + (1 - \gamma) d_k / \sum_n d_n]}.$$

主要参考模态为 $m^* = \arg \max_m I_m$ 。 $I_t + I_a + I_v = 1$ ，便于写入 CSV 和绘制堆叠条形图。

举个例子。完整输入预测强度为 2.3。遮掉文本以后变成 0.4，遮掉语音以后变成 1.9，遮掉视觉以后变成 2.1。文本被拿走时变化最大，所以这个样本主要依赖文本。门控权重如果也给文本较高分，两种证据互相支持；如果两者相反，就要回头检查模型是否真的学到了稳定规则。

作用程度最好保留三位小数，并让三项相加等于 1。主要模态不要永远固定为文本。若最终几乎所有样本都是文本最重要，需要检查模型是否忽略了语音和视觉，也要和单模态实验对照。

8.2 关键证据定位

对模态 m 的第 i 个位置或长度为 w 的局部窗口进行遮挡，重新预测并计算

$$s_{m,i} = |\hat{y} - \hat{y}_{-(m,i)}| + \eta \text{JSD}(\mathbf{p}, \mathbf{p}_{-(m,i)}).$$

将 $s_{m,i}$ 归一化后，选择累计贡献达到 60% 的最少非重叠窗口，或选取 Top- K 窗口作为关键证据。利用问题 1 保存的 $[s_i, e_i]$ 映射：

- 文本证据输出原始单词/短语及其时间；
- 语音证据输出起止秒数，并展示能量、音高等曲线；

- 视觉证据输出起止秒数和区间内置信度最高的关键帧。

局部遮挡相当于做一次小实验：只拿掉第 20 到第 24 个位置，再看结果变多少。把窗口沿时间轴滑过去，就能得到一条重要性曲线。曲线峰值对应关键区间。窗口太短时结果容易抖，太长时定位又不精确，可以在验证集比较 $w = 1, 3, 5$ 三种长度。

文本证据直接输出词组，学生一眼就能看懂；音频和视觉则输出秒数。视觉关键帧不必每个窗口都截很多张，选窗口中人脸检测最清楚的一帧即可。如果该时段没有可靠人脸，就老实标记“视觉证据不可用”，不要为了版面硬放一张模糊图。

8.3 解释卡可以长什么样

每个典型样本用半页到一页做一张解释卡，内容不用太满：样本 ID、原文、真实标签、预测标签、预测强度、三模态作用比例、主要模态、关键时间段和一句人工核查。下面是一份文字模板。

表 4: 典型样本解释卡模板

项目	内容
样本编号	video_id\$_clip_id
预测结果	正向, 强度 2.10, 正向概率 0.86
模态作用	文本 0.58, 语音 0.27, 视觉 0.15
主要参考模态	文本
关键文本	“really enjoyed”, 时间 3.2–4.1 s
关键语音	3.0–4.4 s, 音高和能量上升
关键画面	第 4.0 s 附近, 嘴角上扬、头部轻微前倾
人工核查	三种信号方向一致, 解释与原视频相符

8.4 解释忠实度检验

解释不能只“看起来合理”，还应量化验证：

1. **删除检验**：依次遮挡最重要证据，预测置信度或强度绝对值应快速下降；
2. **保留检验**：仅保留最重要证据时，预测应尽量接近原预测；
3. **随机基线**：相同长度的随机窗口，其影响应显著弱于关键窗口；
4. **稳定性**：对输入加入轻微噪声后，Top- K 证据位置的 Jaccard 相似度应保持较高水平。

9 提交文件设计

删除检验可以画成一条曲线：按照重要性从高到低逐步删证据，观察正确类别概率下降速度。随机删除作为对照。如果关键证据曲线下降得更快，说明解释至少在模型内部是忠实的。保留检验则反过来，只留下最重要的部分，看能否维持原预测。

附件 3 预测结果建议字段为：解释稳定性也值得看。同一条样本加入很小的特征噪声，预测类别没有变化时，关键证据不应该从开头突然跳到结尾。可用 Top- K 位置的 Jaccard 相似度衡量。这个实验计算量不大，却能让问题 3 更完整。

9.1 问题 3 最容易出现的假解释

第一种是假装注意力就是因果贡献。注意力图可以展示，但不要把它当唯一证据。第二种是只挑一个“讲得通”的样本，不报告整体解释统计。第三种是关键片段无法回到原视频，只给出序号没有时间戳。第四种是解释和预测方向矛盾，例如模型判正向，列出的关键文本却全是强烈负向词，却没有讨论讽刺或模态冲突。

比较稳的写法是：先给全部附件 4 样本的结构化解释结果，再挑两到三条做详细解释卡，其中至少包含一条三模态意见不一致的困难样本。这样既有全量结果，也能体现分析深度。

10 代码怎么组织，才不会越写越乱

建议把数据处理、模型、实验和导出分开。文件名可以不同，但职责最好清楚：

```
project/
  configs/      # 数据路径、随机种子、模型参数
  data/         # 数据读取、标准化、掩码生成
  features/     # 问题1三模态特征提取
  models/       # 编码器、门控、分类与回归头
  explain/      # 模态消融、滑窗遮挡、解释卡
  train.py      # 训练入口
  evaluate.py   # 验证集指标与消融实验
  predict_q2.py # 附件3推理
  predict_q3.py # 附件4推理与解释
  export_tables.py # 自动生成CSV和论文表格
```

配置文件里至少记录数据版本、隐藏维度、层数、学习率、批大小、损失权重、缺失率范围和随机种子。不要把这些数字散落在十几个脚本里。一次实验只改配置，不改训练代码，后面才知道结果是怎么来的。

第一版模型可以从隐藏维度 128、两层编码器、批大小 32、AdamW 优化器和 10^{-4} 左右的学习率起步。这里不是说这些数一定最好，而是给学生一个能开跑的起点。早停轮数可设为 8 到 10 轮，总轮数先给 50 轮上限。最终参数要由验证集决定。

每次训练保存三样东西：最佳权重、完整配置、每轮指标。图表尽量从日志自动生成，不要手工抄数字。手工抄表最容易把验证集和测试集、百分数和小数弄混。

11 提交结果怎么整理

附件 3 预测结果建议包含：

```
id, polarity_pred, intensity_pred,
p_negative, p_neutral, p_positive,
text_missing_rate, audio_missing_rate, vision_missing_rate
```

附件 4 预测与解释结果建议字段为：附件 4 预测与解释结果建议包含：

```
id, polarity_pred, intensity_pred,
main_modality, text_importance, audio_importance, vision_importance,
text_evidence, audio_evidence_start, audio_evidence_end,
vision_evidence_start, vision_evidence_end, key_frame_index
```

若一个样本包含多个关键窗口，可用分号连接，或另建长表 `id, modality, rank, start, end, score, evidence`，避免在单元格中塞入过长内容。若一个样本有多个关键窗口，可以用分号连接。更推荐另建长表 `id, modality, rank, start, end, score, evidence`，一行只放一个证据窗口。长表更容易排序、画图和检查。

12 训练、验证与风险控制

导出以后做四个简单检查：ID 是否缺失或重复；分类值是否只来自三个合法类别；强度是否都在 $[-3, 3]$ ；三种模态作用程度是否相加约等于 1。最后随机抽五行，与程序内存中的预测逐项对照。

- 使用验证集选择模型结构、损失权重、决策阈值和早停轮次；专项测试集不参与调参；
- 至少运行 3 个随机种子，报告均值和标准差；
- 类别不均衡时使用加权交叉熵或平衡采样，但权重只由训练集计算；
- 以 Macro-F1 和 MAE 作为主要早停依据，避免 Accuracy 掩盖中性小类表现；
- 保存配置文件、随机种子、软件版本、最佳模型哈希和每次实验日志；
- 题目禁止引入额外情感数据，预训练模型只能作为通用特征提取器，不能在外部情感语料上再次训练；
- 附件总大小受限，模型参数可只提交最佳权重，原始视频不重复打包，图像尽量使用矢量格式。

附件总大小不超过 50MB。没有必要重复打包原始视频，也不要保存每一轮模型。通常保留最佳权重、配置、必要代码、运行说明、问题 1 生成的特征以及两份专项结果即可。身份信息要在压缩前统一搜索并删除。

13 论文中最值得突出的创新点

14 论文怎么写才不空

1. **统一时间坐标**：问题 1 保存的时间映射同时服务于缺失建模和解释回溯，使三问形成闭环；
2. **连续区间缺失增强**：训练机制与题目真实缺失定义一致，优于独立随机 Dropout；
3. **可靠性动态融合**：模型权重同时依赖特征内容、缺失比例和最长连续缺失长度；
4. **完整-缺失双视图一致性**：利用同一样本的完整视图约束缺失视图，而不引入任何额外数据；
5. **反事实可解释性**：用实际预测变化而非单纯注意力权重衡量模态和局部片段的重要性；
6. **解释质量可量化**：通过删除、保留、随机和稳定性四类检验评价解释是否忠实。

论文不必从摘要开始写。更省力的顺序是先做表和图，再围着结果写文字。方法部分回

答“怎么做”，实验部分回答“有没有用”，分析部分回答“为什么会这样”。这三类内容不要混成一大段。

15 推荐实施顺序

问题 1 建议至少放一张总流程图、一张典型样本时间轴和一张 100 条样本汇总表。正文不一定塞下 100 行，可以展示统计摘要，并把全量表放到附件，但正文要明确告诉读者成功率、异常数和处理规则。

1. 先写统一数据读取器，完成字段、形状、标签和零值掩码审计；
2. 训练直接拼接的分类-回归基线，确保指标计算正确；
3. 加入连续缺失生成器，绘制基线在不同缺失率下的退化曲线；
4. 实现模态编码器和动态门控，再依次加入重构与一致性损失；
5. 固定问题 2 最佳模型，完成附件 3 推理；
6. 在完整输入模型上实现模态消融和滑窗遮挡，生成解释卡与忠实度实验；
7. 最后处理附件 1 的 100 条原始视频，生成可追溯特征和典型对齐图；
8. 自动导出论文表格、CSV、配置、日志和附件目录清单，避免手工复制出错。

问题 2 的核心表是基线与完整模型对比，核心图是不同缺失率下的退化曲线。消融表只改一个模块，别同时拿掉两三项，否则无法判断是哪一项起作用。错误分析不要只挑成功案例，至少展示一次预测翻转并说明原因。

16 结论

问题 3 先放整体统计，例如多少样本主要依赖文本、语音和视觉；再放典型解释卡和重要性曲线；最后用删除、保留或随机对照说明解释是否可信。这样的顺序比先放几张漂亮热力图更扎实。

本方案以“对齐、鲁棒、可解释”为递进主线，用统一掩码和时间映射连接三个问题。问题 1 提供可核验输入，问题 2 通过连续缺失增强和动态可靠性门控保证预测稳定，问题 3 用反事实遮挡给出可量化、可回看的证据。实际论文中应以验证集结果、消融实验和专项测试输出替换所有定性预期，避免在没有实验支持时宣称某个模态必然最重要或模型必然优于全部基线。“创新点”不要列六七条。真正能站住的两三条就够：一是训练时模拟连续区间缺失，而不是随意打散；二是门控权重同时看内容和缺失情况；三是用反事实遮挡定位证据，并且能回到原视频核查。每一条创新后面都应对应一组实验。

17 训练与验证时必须守住的边界

验证集用来选模型、超参数和阈值，附件 3 和附件 4 不参与调参。至少运行三个随机种子，报告均值和标准差。若时间不够把所有模型都跑三次，至少保证最终模型和主

要基线有重复实验。

标准化参数、类别权重和缺失增强规则都只能根据训练集确定。题目不允许引入其他情感数据训练或调参，预训练模型只能作为通用特征提取器。论文里把这件事写清楚，避免读者误以为使用了额外标签。

早停不能只看 Accuracy。建议同时记录 Macro-F1、MAE 和 Pearson r ，再选一个预先规定的综合准则。例如先保证 Macro-F1，再在相近模型中选择 MAE 更低者。不要看完结果以后临时更换主指标。

18 一份可以照着执行的顺序

第一步，写统一数据读取器，完成字段、形状、标签和掩码检查。第二步，训练直接拼接的分类-回归基线，确认评价函数正确。第三步，加入连续缺失生成器，先画出基线退化曲线。

第四步，实现三个模态编码器和动态门控。第五步，依次尝试一致性约束和重构损失，每次只加一项。第六步，固定问题 2 最终模型，完成附件 3 推理。

第七步，在完整输入模型上做模态消融和滑窗遮挡，生成附件 4 解释结果。第八步，处理附件 1 的 100 条原始视频，生成三模态特征、时间映射和典型对齐图。问题 1 放在最后集中跑，并不代表论文最后写它；只是特征提取耗时较长，可以和模型实验并行安排。

最后统一导出表格、图片、CSV、配置和运行日志。把整个流程从空目录重新跑一遍，确认没有依赖临时文件或个人绝对路径。

19 学生常问的几个问题

模型一定要很新吗？

不一定。比赛更看重问题是否回答完整。一个处理正确、实验充分的中等规模模型，通常比结构很新但没有消融、无法复现的模型更有说服力。

文本通常最强，还需要语音和视觉吗？

需要。题目本身就在问多模态是否能补充单模态。文本可能占优势，但讽刺、停顿、音调和表情会提供额外信息。是否有帮助要通过单模态和多模态对比来证明。

中性标签只有精确的 0，回归值很难等于 0 怎么办？

不要用回归值是否等于 0 来判断中性。保留独立三分类头，用分类概率决定极性；回归头只负责强度。两个任务通过辅助一致性损失减少冲突。

解释结果和人的感觉不一致怎么办？

先看模型预测本身是否正确。若预测错误，解释只能说明模型为什么错，不能证明真实情绪。若预测正确但证据奇怪，再检查时间映射、遮挡窗口和掩码是否有问题。解释不是给模型“圆答案”，而是把它的实际依据暴露出来。

没有足够算力怎么办？

优先使用对齐版特征，减小隐藏维度和编码器层数，固定预训练文本特征，不在比赛数据上重新训练大模型。遮挡解释可以只对附件 4 和少量验证样本计算，不必对全部训练样本反复跑。

20 最后检查清单

提交前逐项确认：100 条原始视频是否全部有处理记录；特征位置能否映射回原视频；训练、验证和专项测试是否使用同一数据版本；缺失掩码是否区分正常填充；分类和回归指标是否都已报告；消融实验是否一次只改一个因素；附件 3 和附件 4 是否从未参与调参；解释是否包含模态比例、时间位置和原始证据；CSV 是否无重复 ID、无越界值；代码能否按说明从头运行。

这套思路的重点不在堆很多名词。问题 1 把时间和数据对齐，问题 2 让模型见过连续缺失并学会调整权重，问题 3 用真实的输出变化找到证据。把这三件事做扎实，再用表格和图把过程讲清楚，就已经是一份完整的建模方案。